organelle-evo 돌아보기

유전체 진화 법칙 프로젝트 · 2026-10-09 기준 정리 · 용어 사전 포함

> **한 줄 요약** — 실제 생물 수백 종의 유전체를 비교해 "진화가 따르는 규칙"을 찾고, 그 규칙이 진짜인지 엄격하게 시험해 왔습니다. 된 것도 있고 안 된 것이 더 많으며, 이 프로젝트는 **안 된 것을 숨기지 않고 기록하는 것**을 가장 중요한 원칙으로 둡니다.

1. 무엇을 묻는 프로젝트인가

세 가지 큰 진화적 변화를 봅니다.

1. **공생 → 소기관**: 세균이 다른 세포 안에 들어가 미토콘드리아·엽록체가 되는 과정
2. **자유생활 → 기생**
3. **보통 환경 → 극한 환경** (뜨거운 곳, 짠 곳 등)

두 수준에서 봅니다: **유전자 구성**(어떤 유전자군을 잃고 늘리는가)과 **단백질 조성**(아미노산 비율의 변화). 그리고 최근에는 **조상 복원**이 더해졌습니다 — 오늘날의 생물들을 보고 옛 조상이 어떤 유전자를 갖고 있었는지 거꾸로 추정하는 일입니다.

2. 어떻게 하나 — 작업의 흐름

1. **자료 모으기**: UniProt 등 공개 데이터베이스에서 수백 종의 단백질 목록을 받습니다. 실험실이나 서버가 없으므로 GitHub Actions(무료 클라우드 컴퓨터)가 대신 받습니다.
2. **유전자군 표**: 종마다 어떤 Pfam 유전자군이 있는지 있음(1)/없음(0) 표를 만듭니다.
3. **계통수**: 리보솜 단백질 서열로 종들의 족보 나무를 그립니다.
4. **모형**: 나무 위에서 유전자군이 생기고(획득) 사라지는(손실) 확률 모형을 맞춥니다.
5. **기준선과 비교**: 결과를 항상 단순한 방법과 나란히 놓습니다. 단순한 방법을 못 이기면 그 결과는 의미가 없습니다.
6. **법칙으로 고정**: 결과를 숫자·한계와 함께 `laws/`에 저장하고, 옵시디언 볼트로 정리합니다. 이미 만든 법칙은 덮어쓰지 않고 새 판을 추가합니다.

3. 지금까지의 흐름

초기 — 법칙 학습과 중요한 음성 결과들

- 환경 정보는 "어떤 유전자를 잃을지" 예측을 개선하지 못했습니다 (0.813 vs 0.814).
- 법칙은 대부분 단순 암기를 이기지 못했습니다.
- 미생물에서 찾은 법칙은 동물 세포로 옮겨 쓸 수 없었습니다.
- 수억 년 자료로 만든 법칙은 5만 세대 실험실 진화에 통하지 않았습니다.

그래서 기후 변화에 따른 병원체 예측 같은 요청은 과학적 근거가 없어 하지 않습니다.

조상 복원

조상	정답 채점 (우리 / 현생 빈도)	내용
균류 조상	0.850 / 0.745	유전자군 약 4,300개, 편모 유전자 보유
엽록체 조상 (남세균에서 갈라진 지점)	0.995 / 0.976	매우 정확, 약 2,400–2,500개
LECA 1판	0.62–0.82	약함, 크기 인용 안 함
LECA 2판 (나무를 다시 그림)	0.81–0.86 / 0.71–0.74	약 3,900–4,600개 (뿌리 위치에 따라)

정답 채점 = 우리 모형으로 만든 가짜 자료에서 맞히는지 본 시험. 아래 4절에서 이 시험의 한계가 드러납니다.

진화 경로 추가

- **산소 호흡 → 무산소**: **약한 양성**. 독립적으로 무산소가 된 6개 계통 모두에서 호흡 사슬이 사라졌습니다. 희귀도와 합치면 +0.021 [0.008, 0.035].
- **단세포 → 다세포**: **음성**. 다세포가 될 때마다 같은 유전자를 얻는다는 규칙은 보이지 않았습니다 (−0.195).

외부 검증 세 번 (모두 사전 등록)

비교	결과	판정
① Zmasek 2011 (Dollo 절약법 집합)	LECA 0.900 vs 빈도 0.912, −0.012	**음성** (기준의 판정력이 약함)
② Vosseberg 2021 (유전자마다 계통수로 판정한 LECA)	0.866 vs 0.954, −0.088 [−0.096, −0.080]	**음성**
③ 모형 10개 + 결합형 3개	최선의 트리 모형 −0.031, 결합형 +0.0005	트리 모형 **모두 음성**, 선택된 결합형 **무승부**

4. 가장 중요한 교훈 세 가지

> **① 우리 "정답 채점"은 자기 자신과의 시험이었다.**
> 우리 모형으로 가짜 자료를 만들고 우리 모형이 맞히는지 봤기 때문에, 모형 자체의 편향은 볼 수 없었습니다. 외부 자료와 비교하자 바로 드러났습니다.

> **② 편향의 정체: 유전자군마다 따로 맞춘 획득률 (과적합).**
> 오늘날 20–50%의 종에만 있는 유전자군을 계통수는 78%가 LECA에 있었다고 보는데(여러 번 잃음), 우리 모형은 평균 0.29로 "나중에 새로 생겼다"고 봤습니다. 그 결과 LECA 크기를 15–26% 작게 잡았습니다. 모든 유전자군이 같은 획득/손실 비를 쓰게 하자(M7) 일치도가 0.865 → 0.926으로 올랐는데, 정작 우리 유전체 자료에 대한 적합도는 원래 모형이 더 높았습니다. **자료에 더 잘 맞는 모형이 조상은 더 틀렸습니다.**

> **③ "흔하면 오래됐다"는 매우 강력하다.**
> 현생 빈도(몇 종이 가졌나)만으로 계통수 판정을 0.954 맞혔습니다. 지금 가진 자료(유전자군 유무 + 리보솜 계통수)로는 이것을 넘지 못했습니다. 넘으려면 유전자군 안의 서열 족보까지 봐야 할 것 같습니다.

모형 시험 결과 자세히 (시험 절반 2,801개)

모형	설명	AUROC	빈도 대비
M0	현재 모형 (유전자군별 자유 획득률)	0.865	−0.092
M7	**모든 유전자군 공통 획득/손실 비**	**0.926**	**−0.031**
M9	공통 비 + 공통 뿌리확률	0.912	−0.045
M6	돌로에 가깝게 (획득 거의 금지)	0.886	−0.071
M1·M2·M8	뿌리확률만 바꿈	0.79–0.85	−0.11 ~ −0.17
S2	빈도 + M0 결합 (학습)	0.957	+0.0005 (무승부)

5. 성적표 (볼트 기준)

법칙 45개 중 **양성 11**, **음성 12**, **무승부 5**. 나머지는 보고·분석형이거나 검증이 없는 것입니다. 음성이 양성보다 많고, 그것이 정직한 상태입니다.

6. 용어 사전

생물 쪽

유전체
한 생물이 가진 유전 정보 전체.

단백질체 (프로테옴)
그 생물이 만드는 단백질 목록. 우리가 실제로 받은 자료.

Pfam (유전자군)
단백질을 비슷한 "부품"끼리 묶은 분류 번호(예: PF00780). 우리 분석의 기본 단위.

소기관
세포 안의 기관. 미토콘드리아(에너지 생산), 엽록체(광합성).

내공생
한 생물이 다른 생물의 세포 안에 들어가 사는 것. 소기관의 기원.

LECA
모든 진핵생물(사람·식물·버섯·아메바)의 마지막 공통 조상. 약 15–20억 년 전.

초군 (supergroup)
진핵생물의 가장 큰 갈래들(후편모생물, 아메바류, 식물류 등).

수평 전달 (HGT)
부모→자식이 아니라 옆의 다른 종에게서 유전자를 받는 것.

미토솜 · 수소생성체
무산소 생물에서 퇴화한 미토콘드리아.

계통·모형 쪽

계통수
종들의 족보 나무.

뿌리
계통수에서 가장 오래된 지점. LECA의 뿌리 위치는 학계에서도 모르므로 4곳을 다 시험하고 가장 보수적인 값을 씀.

외군
뿌리를 정하려고 일부러 넣는 바깥 친척.

획득/손실 모형 (마르코프 모형)
나무의 가지를 따라가며 유전자가 "생길 확률"과 "사라질 확률"로 계산하는 모형.

사후확률 (P)
모형이 계산한 "조상에게 이 유전자가 있었을 확률". P ≥ 0.9면 "있었다"로 봄.

Dollo 법칙 / 절약법
"한 번 생긴 것은 다시 생기지 않는다"고 가정하는 단순한 복원 방법.

완전도
단백질 목록이 빠짐없이 다 있는 정도. 덜 완전하면 "없음"이 진짜 없음이 아닐 수 있음.

앙상블
비슷하게 좋은 모형 여러 개의 평균.

부트스트랩
자료를 무작위로 다시 뽑아 여러 번 계산해 결과가 얼마나 흔들리는지 보는 방법.

검증·통계 쪽

기준선
비교 대상이 되는 단순한 방법. 이걸 못 이기면 그 방법은 의미가 없음. **현생 빈도**(오늘날 몇 %의 종이 가졌나 — 조상 복원의 기준선), **암기**(본 답을 외워 맞히기), **희귀도**(드문 유전자일수록 잃는다고 보기).

AUROC
맞는 것과 틀린 것을 얼마나 잘 줄 세우는지. 0.5 = 동전 던지기, 1.0 = 완벽.

95% 신뢰구간 [a, b]
진짜 값이 거의 확실히 들어 있는 범위.

양성 / 음성 / 무승부
차이의 신뢰구간이 0보다 위면 양성, 아래면 음성, 0을 걸치면 무승부.

알려진 정답 채점
정답을 아는 가짜 자료로 하는 시험. 편하지만 같은 모형으로 만들면 자기 맹점을 못 봄.

잎 숨기기 검증
몇 종을 가리고 그 종의 유전자를 맞히는지 보는 시험.

과적합
가진 자료에 너무 딱 맞춰서, 새로운 질문에는 오히려 틀리는 것.

사전 등록

자료를 보기 전에 "무엇을 어떻게 판정하고 무엇을 예측하는지" 먼저 기록(커밋)해 두는 것. 결과를 보고 기준을 바꾸는 것을 막음.

보정 절반 / 시험 절반

자료를 반으로 나눠, 한쪽으로 모형을 고르고 학습한 뒤 다른 쪽으로 한 번만 시험하는 것.

층화 AUROC

빈도가 비슷한 것끼리 묶은 뒤 그 안에서 잰 AUROC. "빈도 말고 다른 정보가 있나"를 봄.

도구 쪽

GitHub Actions

무료로 빌리는 클라우드 컴퓨터. 자료 수집과 긴 계산을 여기서 함.

FastTree / IQ-TREE

계통수를 그리는 프로그램. IQ-TREE가 더 정확하지만 느림.

법칙 카드 (laws/*.json)

결과를 숫자·한계(caveats)와 함께 고정한 파일. 덮어쓰지 않고 새 판(_v2)만 추가.

볼트

옵시디언으로 보는 연구 노트 모음. PC에 15분마다 동기화.

7. 지금 위치와 다음 갈림길

"우리 방법이 언제 맞고 언제 틀리는지"를 외부 기준으로 처음 정직하게 잰 상태입니다. 엽록체·균류 조상은 비교적 믿을 만하지만(외부 계통수 기준 확인은 아직), LECA는 순위는 대략 맞되 "흔함" 이상의 정보가 없고 크기를 작게 잡습니다.

- **가벼운 길**: 공통 획득률 모형(M7)으로 LECA 3판을 만들고, 균류·엽록체도 같은 방식으로 다시 확인.
- **무거운 길**: 유전자군 안의 서열 족보를 직접 그리기 (Actions 수 시간).

근거 파일: docs/HANDOFF.md, docs/preregistration/, results/external_benchmark/, results/leca_models/ (저장소 minjae-05-28/-ai)